

# Отчет по БДЗ №2

## Глубинное обучение 1

Назаров Никита

16 марта 2026 г.

Я провел следующие эксперименты, чтобы прийти к итоговому решению:

### 1. RNN (GRU) Encoder-Decoder + Teacher Forcing + Adam

- **Модель:** Базовая архитектура Encoder-Decoder на основе однослойных GRU. В качестве энкодера используется GRU, передающий скрытое состояние (hidden state) в декодер. Декодер также построен на GRU с линейным слоем на выходе. Размер эмбедингов - 256, размер скрытого слоя - 512. При обучении использовался механизм Teacher Forcing с вероятностью 0.5.
- **Optimizer:** Adam с фиксированным learning rate  $10^{-3}$ .
- **Scheduler:** Не использовался
- **Кол-во эпох:** 5
- **Результат:** Average validation loss 4.8581. Качество перевода на тестовой фразе ("ein kleiner junge spielt im park .") после 5 эпох: "a little boy in the .". Модель демонстрирует базовую способность улавливать структуру предложения (субъект), но из-за отсутствия механизма внимания (Attention) и малого количества эпох перевод обрывается и теряет смысл в конце. Динамика валидационного лосса (с 5.23 до 4.85) показывает, что модель продолжает учиться, но текущей сложности архитектуры недостаточно для качественного перевода сложных предложений.

### 2. Transformer + BPE + OneCycleLR


- **Модель:** Полноценная архитектура Transformer (Sequence-to-Sequence).
  - Количество слоев: 3 (для энкодера и декодера).
  - Количество голов аттеншна: 8.
  - Размерность эмбедингов: 256.
  - Dropout: 0.3 для предотвращения переобучения.
  - Токенизация: BPE с размером словаря 8000.
- **Optimizer:** AdamW ( $lr = 10^{-3}$ ,  $weight_{decay} = 0.01$ ).AdamW.
- **Scheduler:** OneCycleLR. Этот шедулер позволяет динамично изменять learning rate: сначала плавно прогревать (warmup) в течение первых 5% шагов, а затем снижать по косинусной кривой. Это стабилизирует обучение на высоких LR.

- **Loss Function:** CrossEntropyLoss с Label Smoothing (0.1) и игнорированием паддинг-токенов. Label smoothing помогает модели не быть "слишком уверенной что полезно при работе с шумными данными или малым словарем.
- **Кол-во эпох:** 20.
- **Результат:** На графиках видна классическая динамика обучения Трансформера: резкое падение лосса на первых 5 эпохах и последующий выход на плато.
- **Анализ:** Архитектура показала себя значительно мощнее предыдущих итераций. Однако использование BPE на 8000 токенов для данного датасета (где данные уже были предварительно токенизированы - увидел потом) оказалось избыточным. Несмотря на это, Self-Attention позволил модели гораздо точнее выстраивать грамматические связи в длинных предложениях.




### 3. Deep Transformer + CosineAnnealing

- **Модель:** Расширенная архитектура Transformer.
  - Конфигурация: 4 слоя, 8 голов,  $d_{model} = 512$ , Dropout = 0.1.
  - Токенизация: Использование стандартных словарей датасета (без BPE).
- **Optimizer & Scheduler:** AdamW ( $lr = 3 \times 10^{-4}$ ) и CosineAnnealingLR.
- **Результат (до 9 эпохи):** Модель показывала лучшую динамику среди всех экспериментов. К 8-й эпохе Validation Loss достиг **3.66**, а метрика BLEU выросла до своего пика - **15.61**. Перевод тестовой фразы стал осмысленным: *"a young boy in the park plays a little bit of a park ."*
- **Проблема (10+ эпохи):** На 10-й эпохе произошел резкий скачок лосса до **15.37** и обрушение BLEU до **0.31**. Модель перестала генерировать связный текст (пустые строки или случайные токены).
- **Анализ:** Вероятной причиной коллапса стал взрыв градиента или слишком высокий learning rate для такой глубокой архитектуры на данном этапе обучения. Для стабилизации в добавим Gradient Clipping, уменьшим базовый LR.




## 4. Stable Deep Transformer + Low LR + CosineAnnealing

- **Модель:** Глубокая архитектура Transformer.
  - Конфигурация: 4 слоя, 8 голов,  $d_{model} = 512$ , Dropout = 0.1.
  - Токенизация: Использовались стандартные словари датасета.
- **Optimizer:** AdamW со значительно сниженным learning rate ( $5 \times 10^{-5}$ ) и weight decay 0.01. Снижение LR стало критическим фактором для обеспечения стабильности обучения глубокой модели.
- **Scheduler:** CosineAnnealingLR ( $T_{max} = 30, \eta_{min} = 10^{-7}$ ). Планировщик обеспечил очень плавную сходимость к локальному минимуму.
- **Результат:**
  - Лучший Validation Loss: **4.2007**.
  - Лучший BLEU: **11.62** (достигнут на 24 эпохе).
- **Анализ:** Данный эксперимент подтверждает гипотезу о том, что для глубоких трансформеров на небольших датасетах критически важен подбор темпа обучения. Модель показала отличную стабильность (отсутствие скачков на графике), однако из-за малого LR за 30 эпох она не успела достичь тех же значений BLEU, что и в прошлом запуске до его падения.



## 5. Deep Transformer + Optimized LR + Best BLEU

- **Модель:** Глубокая архитектура Transformer (4 слоя, 8 голов,  $d_{model} = 512$ , Dropout = 0.1).
- **Настройка обучения:**
  - Optimizer: AdamW ( $lr = 10^{-4}$ ). Данный темп обучения оказался топ для баланса между скоростью сходимости и стабильностью градиентов
  - Scheduler: CosineAnnealingLR ( $T_{max} = 30$ ).
  - Loss Function: CrossEntropyLoss (Label Smoothing = 0.1).
- **Результат:**
  - Лучший Validation Loss: **3.27** (значительное улучшение относительно предыдущих итераций).
  - Максимальный BLEU: **20.65** (достигнут на 26 эпохе).
- **Динамика:** На графике наблюдается плавная экспоненциальная сходимость. В отличие от эксперимента с  $lr = 3 \cdot 10^{-4}$ , здесь не зафиксировано аномальных скачков лосса, что подтверждает важность точного подбора гиперпараметров для глубоких сетей.



## 6. Transformer with Beam Search Inference

- **Архитектура и гиперпараметры:**

- Конфигурация: 4 слоя, 8 голов,  $d_{model} = 512$ .
- Регуляризация: Dropout 0.1, Label Smoothing 0.1.
- Оптимизация: AdamW ( $lr = 10^{-4}$ ), CosineAnnealingLR.

- **Инференс (Beam Search):** В отличие от предыдущих запусков, для генерации перевода на валидационной выборке использовался Beam Search. Это повысило BLEU

- **Результаты:**

- Лучший BLEU: **21.47** (эпоха 25).
- Итоговый Validation Loss: **3.285**.

- **Анализ качества:** Модель демонстрирует высокую уверенность в структуре предложения.

- **Сходимость:** Графики лосса показывают очень стабильное поведение. Незначительные колебания BLEU после 20-й эпохи связаны с тем, что модель находится в области локального минимума и уточняет веса для редких токенов.

- **Вывод:** Комбинация оптимального темпа обучения и Beam Search дала наилучший результат в серии экспериментов. Прирост BLEU составил примерно +0.8 пункта относительно аналогичной модели с Greedy Search.



## 7. High-Performance Transformer (8 Epochs Snapshot)

- **Конфигурация гиперпараметров (взял из Attention is all you need и поле-тело) и запустил на 15 из 25 эпох, так как сначала самое сильное обучение и прорыв в BLEU):**

- Архитектура: 3 слоя, 8 голов внимания,  $d_{model} = 512$ ,  $d_{ff} = 512$ .
- Регуляризация: Dropout 0.1, Label Smoothing 0.1.

- Оптимизация: Adam ( $lr = 10^{-4}$ ,  $\beta_1 = 0.9$ ,  $\beta_2 = 0.98$ ,  $\epsilon = 10^{-9}$ ).
- Планировщик: CosineAnnealingLR ( $T_{max} = 25$ ).

- **Динамика обучения:**

- Экспоненциальный рост метрики: BLEU вырос с **7.23** (эпоха 1) до **29.62** (эпоха 8).
- Стабильное снижение лосса: Val Loss снизился с 4.67 до 3.32.

Модель идеально восстановила начало фразы ("when i was 11 years old") и уловила ключевой контекст ("sound"), однако всё ещё испытывает трудности со сложными штуками ("waking up") и склонна к заикливанию ("sound of the sound").

- **Сравнение:** Данная модель значительно превосходит предыдущие итерации по скорости сходимости. Уже на 3-й эпохе (BLEU 21.42) она обошла лучший результат предыдущего эксперимента, где использовалось 4 слоя и более низкий  $LR$ .
- **Вывод:** Увеличение размерности эмбедингов до 512 при 3 слоях оказалось более эффективным, чем более глубокая (4 слоя), но медленная модель. Оптимизатор Adam с топовыми параметрами обеспечил более агрессивную, но стабильную сходимость.



## 8. High-Performance Transformer (15 Epochs)

BLEU просто улучшился, стал в чекере 27.75 (возможно, с beam search, еще можно было бы поднять, но не успеваю)

